Kryptoanaliza szyfru Vigenère’a

Dokumentacja programu alfa26/alfa37, opis metod i wyniki eksperymentów

1. Cel i zakres

Program służy do analizy szyfrów Vigenère’a. Obsługuje dwa alfabety i trzy tryby ataku: bez znajomości tekstu jawnego, ze znanym fragmentem oraz znaną pozycją, a także ze znanym fragmentem, którego pozycja jest nieznana. Program zapisuje odszyfrowany tekst, odzyskany klucz oraz log przebiegu analizy.

2. Alfabety i równania szyfru

Wariant	Znaki	Liczba symboli
alfa26	abcdefghijklmnopqrstuvwxyz	26
alfa37	abcdefghijklmnopqrstuvwxyz0123456789 + spacja	37

W alfa37 spacja jest ostatnim symbolem alfabetu, o numerze 36. Cyfry mają numery od 26 do 35. Wartość spacji i cyfr jest używana we wzorze tak samo jak wartość litery. Każdy znak alfabetu zużywa jedną pozycję klucza.

Dla m równego 26 lub 37, tekstu jawnego P, szyfrogramu C i powtarzanego klucza K:

$$C_i = (P_i + K_i) \bmod m$$
$$P_i = (C_i - K_i) \bmod m$$

W programie polskie znaki diakrytyczne są sprowadzane do liter bez znaków diakrytycznych (np. ą → a). W alfa26 spacje, cyfry i interpunkcja są pomijane. W alfa37 spacje i cyfry pozostają w ciągu i przesuwają indeks klucza; interpunkcja oraz znaki końca wiersza są pomijane.

3. Tryby programu

Tryb	Dane podawane przez użytkownika	Co jest wyznaczane
1. Atak statystyczny	Szyfrogram, alfabet, maksymalna długość klucza	Kandydatury długości, klucz i tekst na podstawie statystyki
2. Znany fragment, znana pozycja	Fragment tekstu jawnego i indeks jego początku	Przesunięcia klucza z równania szyfru
3. Znany fragment, pozycja nieznana	Fragment tekstu jawnego	Przeszukiwane są możliwe pozycje fragmentu

Pozycja fragmentu jest liczona od zera po normalizacji szyfrogramu. Na przykład pozycja 11 oznacza dwunasty znak ciągu analizowanego przez program.

4. Metody ataku statystycznego

Indeks koincydencji (IC). Jest to miara częstości powtarzania się symboli. Dla tekstu długości n i liczności n_i poszczególnych symboli:

$$IC = \sum_i n_i (n_i - 1) / (n (n - 1))$$

Przy założeniu długości klucza r, znaki na pozycjach i, i+r, i+2r, ... są szyfrowane tym samym symbolem klucza. Program tworzy takie kolumny i oblicza ich średni indeks koincydencji. Długości, dla których kolumny mają rozkład zbliżony do rozkładu języka, otrzymują wyższą ocenę.

Test Kasiski. Wyszukuje powtarzające się fragmenty szyfrogramu. Odległości pomiędzy ich wystąpieniami mogą być wielokrotnościami długości klucza. Dzielniki tych odległości otrzymują głosy. Metoda jest pomocna, gdy tekst jest dostatecznie długi i zawiera powtarzające się struktury.

Test chi-kwadrat. Dla każdej kolumny sprawdzane są możliwe przesunięcia. Dla danego przesunięcia porównuje się częstości uzyskane po odszyfrowaniu z profilem częstości liter danego języka. Mniejsza wartość statystyki oznacza lepsze dopasowanie jednosymbolowe.

Rozpoznawanie języka. Program porównuje dopasowanie do profilu polskiego i angielskiego. Jest to heurystyka. Przy krótkim, zaszumionym lub niejęzykowym tekście wynik może być błędny. W trybie znanego fragmentu język jest oceniany lokalnie w otoczeniu fragmentu, ponieważ pozostała część szyfrogramu może być mniej wiarygodna.

5. Atak ze znanym fragmentem

Jeżeli znamy fragment tekstu jawnego P i odpowiadający mu fragment szyfrogramu C, symbol klucza można obliczyć bezpośrednio:

$$K_i = (C_i - P_i) \bmod m$$

Jeżeli pozycja fragmentu jest znana, indeks i wynika z tej pozycji. Jeżeli pozycja jest nieznana, program sprawdza kolejne położenia fragmentu. Dla długości fragmentu q i badanego okresu klucza r, gdy $r < q$, kolejne znaki fragmentu ponownie wskazują te same pozycje klucza. Każde powtórne wskazanie musi dać ten sam symbol.

Poprawiona wersja programu liczy liczbę zgodnych powtórzeń i szereguje kandydatów najpierw według tej liczby, a dopiero potem według lokalnej oceny językowej. Jest to ważne: kandydat o długości klucza $r = q$ nie ma żadnych powtórzeń i sam z siebie nie potwierdza klucza. Krótki fragment nie musi wystarczyć do odzyskania całego długiego klucza.

6. Porównanie skuteczności metod

Metoda	Mocna strona	Ograniczenie
Kasiski	Wykorzystuje powtarzające się sekwencje i odległości	Może nie znaleźć sygnału w krótkim tekście
Indeks koincydencji	Działa na kolumnach szyfrowanych tym samym przesunięciem	Często wskazuje też wielokrotności okresu
Chi-kwadrat	Ocenia przesunięcie każdej kolumny	Wymaga odpowiedniej liczby znaków w kolumnie
Znany fragment	Może bezpośrednio wyznaczyć symbole klucza	Fragment musi pokryć pozycje klucza; przy nieznanym położeniu trzeba je przeszukać

W typowych warunkach atak ze znanym fragmentem jest silniejszy niż atak statystyczny. Atak statystyczny jest jednak bardziej uniwersalny, ponieważ nie wymaga żadnej informacji o tekście jawnym.

7. Wpływ długości klucza i szyfrogramu

Dla szyfrogramu długości N i klucza długości r na jedną kolumnę przypada w przybliżeniu N/r symboli. Przy stałym N wzrost r oznacza mniej danych do oszacowania częstości. Wtedy indeks koincydencji i test chi-kwadrat stają się mniej stabilne, a odzyskanie przesunięć jest trudniejsze.

Przykładowa liczba symboli w kolumnie:

Długość szyfrogramu	Klucz 5	Klucz 10	Klucz 20
2 000	400	200	100
30 000	6 000	3 000	1 500

Przy stałej długości klucza dłuższy szyfrogram poprawia estymację częstości i zwiększa liczbę powtórzeń dostępnych dla testu Kasiski. Dla ataku ze znanym tekstem długość fragmentu powinna być co najmniej r, aby wystąpiła informacja o każdej pozycji klucza. Większy r wymaga zatem dłuższego znanego fragmentu.

8. Analiza archiwum szyfrogramów drugiej grupy

Archiwum zawiera osiem szyfrogramów alfa26: cztery o długości 2 000 i cztery o długości 30 000 znaków. Poniżej podano trzy najwyżej ocenione długości klucza. W nawiasie podano średni IC kolumn, a następnie liczbę głosów testu Kasiski. Są to kandydatury, nie potwierdzone długości kluczy.

Plik	N	Top 3 kandydatur (r; IC; głosy Kasiski)
2k_01	2 000	5; 0,05737; 1107 | 10; 0,05708; 576 | 20; 0,05801; 383
2k_02	2 000	8; 0,05942; 504 | 24; 0,05823; 159 | 40; 0,05922; 87
2k_03	2 000	5; 0,06440; 1248 | 10; 0,06479; 533 | 25; 0,06576; 297
2k_04	2 000	8; 0,06430; 906 | 16; 0,06457; 471 | 40; 0,06533; 250
30k_01	30 000	5; 0,05712; 52432 | 10; 0,05715; 26212 | 15; 0,05708; 17110
30k_02	30 000	8; 0,05708; 45230 | 16; 0,05702; 22339 | 24; 0,05711; 14821
30k_03	30 000	5; 0,06476; 57190 | 10; 0,06481; 29685 | 15; 0,06478; 19271
30k_04	30 000	8; 0,06413; 43541 | 16; 0,06411; 21625 | 24; 0,06415; 14294

We wszystkich plikach pojawiają się silne kandydatury 5 albo 8 oraz ich wielokrotności. W tekstach 30 000-znakowych głosy Kasiski są liczniejsze, ponieważ występuje więcej powtarzających się fragmentów. Wiele wielokrotności ma bardzo zbliżony IC, więc sam indeks nie rozstrzyga, czy okres podstawowy wynosi np. 5, czy 10. Wniosek wymaga łącznej interpretacji Kasiski, IC i jakości odszyfrowanego tekstu.

Nie można podać procentowej skuteczności złamania tych ośmiu szyfrogramów, ponieważ archiwum nie zawiera tekstów jawnych ani kluczy. Powyższe zestawienie porównuje sygnały diagnostyczne, a nie odsetek poprawnie odzyskanych kluczy.

9. Diagnostyka przesłanego przypadku test_kpa_01.txt

Dane wejściowe: alfabet alfa26, 85 znaków, tryb 3, znany fragment „kryptografia”, maksymalna badana długość klucza 30.

Parametr	Wynik
Odnaleziona pozycja fragmentu	11 (indeks od zera)
Odzyskany klucz	ENIGMA
Długość klucza	6
Zgodne powtórzenia pozycji klucza	6 - mocne dopasowanie
Rozpoznanie języka	polski (lokalny kontekst)

Otrzymany początek odszyfrowania:

```
wspolczesnakryptografiaeshspswrzrgpiikgkqdjigkaxavlyambegjorhxfcgmnxggqltjkvixnmmcmgq
```

Słowo „kryptografia” występuje na pozycji 11, a poprzedzający je ciąg „wspolczesna” tworzy spójne polskie wyrażenie. Ten sam klucz uzyskano w trybie 2 po podaniu pozycji 11. Atak statystyczny na tak krótki szyfrogram nie odzyskał prawidłowego klucza.

> Ważne ograniczenie: pozostałe znaki odszyfrowanego ciągu nie tworzą czytelnego tekstu. Fragment i klucz są mocno potwierdzone matematycznie, ale reszta szyfrogramu może być uszkodzona, losowa albo zaszyfrowana według innej konwencji. Nie należy uznawać całej wiadomości za poprawnie odzyskaną, dopóki nie zostanie wyjaśniona ta rozbieżność.

10. Kontrolne testy alfa37

Test	Znany fragment	Pozycja	Klucz kontrolny
Z pozycją	a simple question how can a message remain readable on	37	math2026
Bez pozycji	cierpliwosci oraz sprawdzania hipotez analiza szyfrowania w	nieznana	alfa 37key

Oba testy kontrolne zostały ponownie sprawdzone po poprawce i odzyskały podane klucze. W zestawie plików znajdują się szyfrogramy i instrukcja z dokładnymi fragmentami do wpisania. Klucze z instrukcji służą wyłącznie do sprawdzenia wyniku.

11. Uruchomienie i pliki wynikowe

```
python kryptoanaliza_vigenere_alfa37.py
```

Program pyta o nazwę pliku szyfrogramu, alfabet, tryb ataku i maksymalną długość klucza. W trybie 2 pyta dodatkowo o pozycję fragmentu. W trybie 3 samodzielnie przeszukuje możliwe pozycje. Pliki wynikowe są zapisywane obok pliku wejściowego: *_odszyfrowany.txt, *_klucz.txt i *_log.txt.

W przypadku krótkich szyfrogramów ocena językowa oraz atak statystyczny mają charakter orientacyjny. Najsilniejszym potwierdzeniem ataku z fragmentem jest zgodność wielu powtórzonych pozycji klucza. Jeśli fragment jest krótszy od klucza, program nie ma wystarczającej informacji, aby jednoznacznie odtworzyć wszystkie jego symbole.