INSTRUKCJA UŻYTKOWNIKA

Kryptoanaliza szyfru Hilla

Python | alfabety alfa26 i alfa37 | dwa tryby kryptoanalizy

Cel programu. Program wczytuje szyfrogram z pliku, próbuje ustalić rozmiar macierzy i odzyskać klucz szyfrujący, a następnie zapisuje odszyfrowaną wiadomość, klucz, statystyki oraz przebieg pracy w logu. Dostępne są dwa tryby: atak statystyczny na sam szyfrogram oraz atak ze znanym fragmentem tekstu jawnego.

Ważne: atak oparty wyłącznie na szyfrogramie jest statystyczny i heurystyczny. Program wskazuje najlepszego znalezionego kandydata, ale nie gwarantuje, że jest to jedyne lub poprawne rozwiązanie. W trybie ze znanym fragmentem program najpierw próbuje odzyskać klucz z równań szyfru Hilla. Jeżeli fragment jest zbyt krótki, wykorzystuje go jako filtr kandydatów statystycznych; ta druga ścieżka również jest heurystyczna.

1. Wymagania i przygotowanie

Potrzebny jest Python 3 oraz biblioteka NumPy. Program nie wymaga połączenia z internetem.

```
python -m pip install numpy
```

Zapisz plik hill_cryptanalysis.py w wybranym folderze. W tym samym folderze możesz umieścić pliki wejściowe albo podawać do nich pełne ścieżki.

2. Wybór alfabetu

Nazwa	Symbole w kolejności	Moduł
alfa26	abcdefghijklmnopqrstuvwxyz	26
alfa37	abcdefghijklmnopqrstuvwxyz 0123456789	37

W alfa26 spacje, cyfry i interpunkcja są pomijane, więc wynik zawiera tylko małe litery. W alfa37 spacja i cyfry są częścią alfabetu: spacja ma wartość 26, a cyfry 0-9 mają wartości 27-36. Kolejność musi być taka sama jak w szyfrowaniu.

Polskie znaki diakrytyczne są upraszczane, np. ą → a, ł → l, ż/ź → z. W alfa37 spacje z końców linii pliku tekstu jawnego są traktowane jak spacje. Znaki interpunkcyjne są usuwane.

3. Wybór trybu

Tryb A - sam szyfrogram (ciphertext-only)

Wybierz ten tryb, gdy nie znasz tekstu jawnego. Nie musisz podawać żadnego korpusu, tekstu wzorcowego ani fragmentu wiadomości. Program ma wbudowane profile statystyczne języka polskiego i angielskiego, automatycznie ocenia oba i wybiera ten, który lepiej pasuje do kandydatów.

- Dla macierzy 2×2 program sprawdza wszystkie odwracalne macierze, a następnie ocenia najlepsze wyniki na całym szyfrogramie.
- Dla większych macierzy program używa przeszukiwania heurystycznego (symulowanego wyżarzania). To metoda przybliżona, dlatego większy rozmiar może wymagać zwiększenia liczby startów i iteracji.
- Domyślnie program sam porównuje język polski i angielski. W razie potrzeby można ręcznie wymusić jeden model parametrem --language pl albo --language en, ale nie trzeba tego robić.

Wbudowane profile są częścią pliku Python - nie są pobierane z internetu i nie wymagają żadnych dodatkowych plików. Długość profili jest ograniczona, dlatego automatyczny wybór języka i klucza pozostaje heurystyczny i nie gwarantuje poprawnego wyniku dla każdego szyfrogramu.

```
python hill_cryptanalysis.py -c szyfrogram.txt -a alfa26 -m ciphertext -o wyniki

python hill_cryptanalysis.py -c szyfrogram.txt -a alfa37 -m ciphertext -o wyniki
```

Tryb B - znany fragment tekstu jawnego (known-plaintext fragment)

Wybierz ten tryb, gdy znasz słowo lub fragment oryginalnej wiadomości oraz cały szyfrogram. Nie musisz znać miejsca, w którym fragment występuje. Program automatycznie sprawdza możliwe położenia fragmentu, uwzględnia wyrównanie bloków szyfru Hilla i szuka pasującej macierzy klucza.

Fragment musi być dokładny po normalizacji: te same litery, spacje i cyfry, które były obecne w tekście użytym do szyfrowania. W alfa26 spacje i interpunkcja są usuwane; w alfa37 spacje i cyfry są zachowywane. Dla bezpośredniego odzyskiwania klucza macierzą n×n potrzebnych jest co najmniej n pełnych bloków tekstu jawnego (n^2 symboli), a ich wartości muszą dostarczać wystarczających równań. Dla macierzy 2×2 program sprawdza również rozwiązania równań modulo 26 lub 37, gdy proste odwrócenie macierzy bloków nie jest możliwe. Jeżeli fragment jest za krótki, program przechodzi do statystycznego wyszukiwania kandydatów i sprawdza, czy odszyfrowanie zawiera podane słowo. Ten wariant jest heurystyczny. Zwykle lepiej podać 8-15 znaków albo kilka słów.

Po uruchomieniu programu wybierz tryb 2. Następnie wybierz sposób podania fragmentu:

- 1 - wpisz słowo lub fragment w jednej linii i naciśnij Enter. Program od razu przejdzie do analizy.
- 2 - wklej tekst wielowierszowy. Zakończ wpis, umieszczając słowo KONIEC w osobnym wierszu i naciskając Enter.
- 3 - podaj ścieżkę do pliku .txt zawierającego znany fragment.

python hill_cryptanalysis.py -c szyfrogram.txt -a alfa26 -m known-fragment --plaintext-text "znany fragment wiadomości" -o wyniki

python hill_cryptanalysis.py -c szyfrogram.txt -a alfa37 -m known-fragment -p fragment.txt -o wyniki

Jeżeli uruchomisz program z -m known-fragment, ale nie podasz -p/--plaintext ani --plaintext-text, program zapyta, czy chcesz wpisać fragment w jednej linii, wkleić tekst wielowierszowy, czy wskazać plik.

Program podaje w logu oraz w pliku klucz.txt pozycję początku znalezionego fragmentu w odszyfrowanej wiadomości (liczoną od 1). Jeżeli słowo występuje w wiadomości więcej niż raz, wypisane zostaną wszystkie rozpoznane pozycje dla wybranego klucza.

4. Automatyczne ustalanie rozmiaru klucza

Domyślnie program sprawdza macierze od 2×2 do 5×5. Możesz zmienić górną granicę parametrem --max-size (dopuszczalny zakres: 2-8). Rozmiary, dla których długość szyfrogramu nie jest podzielna przez rozmiar bloku, są pomijane. W trybie known-fragment program bada możliwe położenia znanego fragmentu i próbuje odzyskać klucz algebraicznie; jeżeli fragment jest za krótki, korzysta z krótkiej listy kandydatów statystycznych i sprawdza, czy odszyfrowanie zawiera podane słowo. W trybie ciphertext wybierany jest kandydat z najlepszą oceną statystyczną po niewielkiej korekcie preferującej mniejsze macierze.

Program stosuje konwencję wektorów kolumnowych: $C = K \cdot P \pmod m$, gdzie P to blok tekstu jawnego, C to blok szyfrogramu, K to klucz szyfrujący, a m wynosi 26 albo 37. Do odszyfrowania używana jest macierz odwrotna K^{-1} modulo m.

5. Obsługa interaktywna

Najprościej uruchomić program bez argumentów. Program zada pytania o ścieżkę do szyfrogramu, alfabet i tryb pracy. Możesz wybrać atak statystyczny na sam szyfrogram albo atak ze znanym fragmentem. W drugim trybie możesz wpisać słowo w jednej linii, wkleić tekst wielowierszowy albo podać ścieżkę do pliku.

```
python hill_cryptanalysis.py
```

6. Statystyki częstotliwości

Po każdym udanym odszyfrowaniu program wyświetla w konsoli statystyki szyfrogramu oraz osobno tekstu odszyfrowanego. Ten sam raport zapisuje w pliku statystyki.txt w folderze wynikowym.

Tabela liter pokazuje dwa niezależne rankingi obok siebie: litery w badanym tekście oraz litery w języku referencyjnym. Każdy ranking ma kolumnę z literą i kolumnę z udziałem procentowym; oba są sortowane malejąco, od najczęściej występującej litery. Liczby wystąpień poszczególnych liter można odczytać w sekcji unigramów.

Język odniesienia jest wybierany automatycznie. W trybie ciphertext program używa języka modelu, który uzyskał lepszy wynik podczas kryptoanalizy. W trybie known-fragment program ocenia odszyfrowane kandydatury za pomocą wbudowanych modeli polskiego i angielskiego. W razie potrzeby można wymusić język parametrem --language pl albo --language en.

W alfa37 spacje i cyfry są uwzględniane w unigramach, bigramach i trigramach, ale nie w tabeli porównującej częstość liter (ta tabela obejmuje wyłącznie A-Z). Bigramy i trigramy są liczone z nakładaniem; raport pokazuje tylko pięć najczęstszych wzorców. Przy każdym wzorcu podawana jest liczba wystąpień oraz udział procentowy wśród wszystkich okien danego rozmiaru. [SPACJA] oznacza spację w unigramach, a [SP] spację wewnątrz n-gramu.

7. Pliki wynikowe

Plik	Co zawiera
odszyfrowana_wiadomosc.txt	Wiadomość zapisana małymi literami. W alfa26 bez spacji; w alfa37 z zachowanymi spacjami i cyframi.
klucz.txt	Alfabet, rozmiar macierzy, metoda, macierz szyfrująca K i macierz deszyfrująca K^{-1}; w trybie known-fragment także pozycje znalezionego fragmentu.
log.txt	Data i czas, użyte pliki i parametry, testowane rozmiary, wybrany wynik, ostrzeżenia i komunikaty o błędach.
statystyki.txt	Statystyki szyfrogramu i tekstu odszyfrowanego: liczby i udziały liter porównane z częstością referencyjną języka, unigramy, 5 najczęstszych bigramów i 5 najczęstszych trigramów.

Pliki wynikowe są zapisywane do folderu wskazanego parametrem -o/--output. Jeżeli folder nie istnieje, program go utworzy. Przy kolejnym uruchomieniu pliki o tych samych nazwach w tym folderze zostaną nadpisane.

8. Najważniejsze parametry

Parametr	Znaczenie
-c / --ciphertext	Ścieżka do pliku z szyfrogramem.
-a / --alphabet	alfa26 lub alfa37 (domyślnie alfa26).
-m / --mode	ciphertext lub known-fragment (domyślnie ciphertext).
-p / --plaintext	Ścieżka do pliku zawierającego znany fragment tekstu jawnego. Jeżeli jej nie podasz, program zapyta o sposób wpisania fragmentu.
--plaintext-text	Znany fragment tekstu jawnego przekazany jako argument; używany w trybie known-fragment.
--language	auto, pl lub en. Język profilu używanego do oceny kandydatów; nie wymaga zewnętrznego korpusu.
--max-size	Maksymalny rozmiar macierzy; domyślnie 5, zakres 2-8.
--restarts / --iterations	Liczba startów i iteracji dla heurystyki większych macierzy.
-o / --output	Folder wynikowy; domyślnie bieżący folder.

9. Przykładowe testy

W ramach testów program sprawdzono na czterech przykładowych szyfrogramach długości 2 000 i 30 000 znaków. Wszystkie zawierały wyłącznie litery A-Z; wcześniejsza analiza statystyczna wskazała dla nich macierz 2×2.

Plik wejściowy	Alfabet	Wykryty rozmiar
cipher_hill_2k_01.txt	alfa26	2×2
cipher_hill_2k_02.txt	alfa26	2×2
cipher_hill_30k_01.txt	alfa26	2×2
cipher_hill_30k_02.txt	alfa26	2×2

10. Gdy program nie znajduje poprawnego wyniku

- Sprawdź, czy wybrano właściwy alfabet i czy szyfrogram używa dokładnie tej samej kolejności symboli.
- W trybie ciphertext program automatycznie porównuje wbudowane modele polski i angielski; można wymusić język parametrem --language pl/en. Sprawdź, czy odszyfrowany tekst jest czytelny - sama najwyższa ocena nie dowodzi poprawności klucza.
- Zwiększ --max-size, jeżeli podejrzewasz większą macierz. Dla rozmiarów od 3 wzwyż zwiększ --restarts oraz --iterations, pamiętając, że wydłuży to obliczenia.
- W trybie known-fragment upewnij się, że podany fragment jest dokładny i pochodzi z analizowanej wiadomości; sprawdzane jest jego położenie bez konieczności podawania indeksu. Dla krótkiego słowa program może przejść do heurystycznego filtrowania kandydatów statystycznych. Gdy nie znajduje wyniku, sprawdź alfabet, pisownię i normalizację; spróbuj podać dłuższy fragment, najlepiej 8-15 znaków lub kilka słów. Przy niejednoznacznym języku możesz ustawić --language pl albo --language en.