Sprawozdanie z zadania „Grupa 3. Algorytmy analizy”

Autorzy:

- Daria Jaszczak (analizator dla języka polskiego, większość funkcji, część testów oraz sprawozdania)
- Weronika Tyc (część testów, sprawozdanie)
- Mikołaj Ziniak (analizator dla języka angielskiego, dodatkowe funkcje)

Wymagania podstawowe:

1. Stworzenie algorytmów do analizy częstotliwości występowania znaków ALFA26 oraz ALFA37 w szyfrogramach.

Lista spełnionych wymagań: 1.

Opis realizacji zadania:

1. Naszym zadaniem było:

   - przygotowanie analizatora ALFA26 i ALFA37, w tym: wczytanie wskazanego pliku, sprawdzenie alfabetu, liczebności i częstości znaków, ranking oraz czytelny eksport.

     Stworzone zostały funkcje zliczające ilość danych uni-, bi- oraz trigramów, początków i końców słów w tekstach oraz przeliczenie tego na procenty. Następnie powstały funkcje budujące korpusy, obliczające statystyki dla dowolnego tekstu oraz wykrywające dany język lub alfabet, a w międzyczasie także funkcje zczytujące i zapisujące dane w formacie json.

     W celu zbudowania korpusów posłużyliśmy się następującymi tekstami:
     - polski literacki - „Pan Tadeusz” A. Mickiewicz
     - polski współczesny - wpisy z Wikipedii o zróżnicowanej tematyce (Efekt potwierdzenia, Człowiek rozumny, Gdańsk, Kakapo, Sosna, Tyranozaur, Wilk szary. Ewolucja biologiczna, Komórka, II wojna światowa, I wojna światowa, Historia Polski (1572-1697), Nędznicy, Tramwaj, Pitagoras, Platon, Kawa, Pies domowy, Prawo rzymskie, Czarna dziura, Starożytny Egipt)
     - angielski literacki - „Harry Potter i Kamień Filozoficzny” J.K. Rowling

– angielski - wpisy z Wikipedii o zróżnicowanej tematyce (History of Cryptografy, Enigma Machine, Alan Turning, Leonard Euler, Pythagoras, Fibonacci, History of mathematics, Apollo 11, Star Wars, President of the United States, American Civil War, William Shakespeare, House of Tudor, Elizabeth II, Oak, Henry Ford, Human, Cell (biology), Mobile phone, Mammal, Pterodactylus, Tea, Rene Descartes, Cat, Supernova, Law)

Uwaga 1: Początkowo korpusy obu języków rozróżniono na literacki i współczesny. Po namyśle jednak zdecydowaliśmy się je połączyć, aczkolwiek powstałe wcześniej zostawiliśmy.

Uwaga 2: Należy nadmienić, iż dokładne tematy wpisów z Wikipedii w obu językach się nie pokrywają, natomiast mimo to zostały tak dobrane, aby w miarę proporcjonalnie dotyczyły podobnych obszarów słownictwa, a także z wzięciem pod uwagę indywidualnej charakterystyki danego kręgu kulturowego. Naszym zdaniem nie powinno to aż nadto przekładać się na statystyki, choć oczywiście mogło.

- wskazanie częstości referencyjnych dla języka polskiego i angielskiego wraz ze źródłem i opisem normalizacji.
- dodanie instrukcji oraz krótkiego sprawdzenia poprawności.

2. Czas pracy nad analizatorami wyniósł po 2 h dla każdego z języków. Dodatkowo około 6 h zostało poświęcone na resztę funkcji, wyszukiwanie i przetwarzanie tekstów do korpusów, złączenie wszystkiego w całość oraz testowanie. Łączny czas pracy wynosi zatem około 10 h.

Częstości referencyjne:

Tabela 1: Częstości referencyjne dla języka polskiego (ALFA26)

Litera	Częstość występowania według nas	Częstość występowania według Internetu
A	9.79	9.90
O	8.47	8.60
E	8.46	8.77
I	8.25	8.21
N	6.01	5.72
Z	5.40	6.53
S	5.37	4.98
R	4.95	4.69
T	4.41	3.98
W	4.40	4.65
C	4.35	4.36
L	4.26	3.92
Y	3.45	3.76
D	3.33	3.25
K	3.25	3.51
P	3.18	3.13
M	2.67	2.80
U	2.36	2.50
J	2.02	2.28
G	1.69	1.42
H	1.61	1.08
B	1.48	1.47
F	0.52	0.30
V	0.20	0.04
X	0.09	0.02
Q	0.03	0.14

Tabela 2: Częstości referencyjne dla języka angielskiego (ALFA26)

Litera	Częstość występowania według nas	Częstość występowania według Internetu
E	11.45	12.70
T	8.37	9.06
A	8.17	8.17
O	7.35	7.51
I	7.30	6.97
N	6.89	6.75
R	6.85	5.99
S	6.54	6.33
H	4.82	6.09
L	4.24	4.03
D	4.01	4.25
C	3.63	2.78
M	2.79	2.41
U	2.67	2.76
P	2.56	1.93
G	2.18	2.02
F	2.06	2.23
W	1.95	2.36
B	1.81	1.49
Y	1.67	1.97
V	1.22	0.98
K	0.70	0.77
J	0.30	0.15
X	0.23	0.15
Q	0.13	0.10
Z	0.12	0.07

AI zostało użyte do: pisania części kodu, głównie pomocy z obsługą plików typu json, a także zmniejszenia objętości kodu jak w przypadku funkcji o nazwie *roznica_kwadratowa*(); częściowo także przy znajdowaniu długich artykułów na Wikipedii.

Wnioski:

- W celu możliwości porównania naszych danych z tymi dostępnymi w internecie, oczywiście do *a* zostało zsumowane ą, do *z* odpowiednio ż oraz ź itd. Jak widać, zestawienie to różni się nieco o ułamki punktów procentowych w poszczególnych sytuacjach, natomiast nie zanadto. Należy natomiast nadmienić, że rzeczywiście kolejność popularności danych liter jest ździebło zmieniona, co widać, patrząc już na samą topową trójkę w przypadku języka polskiego. Ponadto tam największa różnica występuje w przypadku litery *z*. Z kolei w angielskim też nie ma idealnego dopasowania. Prawdę powiedziawszy, spodziewaliśmy się mniejszych odchyleń względem oficjalnych statystyk - jednak, jak by nie patrzeć, opierają się one na milionach tekstów, a nie tylko tylko raptem ich małym wycinku.

Źródła:

- https://en.wikipedia.org/wiki/Letter_frequency
- https://sjp.pwn.pl/poradnia/haslo/frekwencja-liter-w-polskich-tekstach;7072.html